

DocSearch

Dokumentasi AI: Konsep, RAG, Model,
dan Arah Pengembangan

Dokumen ini fokus pada kecerdasan buatan di DocSearch: bagaimana OCR menjadi konteks untuk AI, perbedaan Search dan Ask AI, komponen RAG yang sudah ada, batasan saat ini, model OpenAI yang dipakai, kemungkinan pertanyaan untuk demo dan pelatihan, serta rekomendasi pengembangan yang tidak bergantung pada kasus per kasus.

Bahasa: Indonesia · Format: dokumentasi teknis (A4)

Versi dokumen: Agustus 2026

Output: DocSearch-Dokumentasi-AI.pdf

Daftar Isi

1. Ringkasan: AI di DocSearch
 2. Konsep sederhana (untuk non-teknis)
 3. Search vs Ask AI
 4. Arsitektur RAG saat ini
 5. Komponen RAG: apa saja yang ada
 6. Alur teknis Ask AI (langkah demi langkah)
 7. Mode intent & batas konteks
 8. Scope, pin dokumen, dan isolasi user
 9. Batasan & risiko jawaban AI saat ini
 10. Arah pengembangan (umum, bukan kasus per kasus)
 11. RAG ke depan: teknik yang cocok ditambahkan
 12. Model AI sekarang vs rekomendasi ke depan
 13. Biaya, audit, dan operasional
 14. Kemungkinan pertanyaan (materi demo & pelatihan)
 15. FAQ AI
-

1. Ringkasan: AI di DocSearch


DocSearch tidak menggantikan arsip PDF dengan AI generatif bebas. AI dipakai sebagai lapisan **pemahaman dan jawaban** di atas teks yang sudah diekstraksi lewat OCR (Paperless-ngx). Tanpa OCR, AI tidak punya bahan bacaan yang andal.

- **Sumber kebenaran:** teks OCR di Paperless + metadata sync (path, ukuran, status).
- **Dua jalur utama:** **Search** (pencarian dokumen + snippet) dan **Ask AI** (tanya jawab berbasis konteks dokumen, RAG).
- **RAG (Retrieval-Augmented Generation):** ambil cuplikan relevan dulu, baru minta model chat menjawab dari cuplikan itu.
- **Isolasi per user:** AI hanya melihat dokumen yang sudah di-ingest untuk akun tersebut (OCR_DONE / SKIPPED).
- **Embedding opsional:** vektor semantic disimpan di tabel *document_chunks* untuk retrieval lebih dalam di Ask AI.

Inti produk: dokumen cloud Bappenas diambil, di-OCR, lalu bisa dicari dan ditanyakan. AI membantu *menjelaskan* dan *menyusun* jawaban, bukan mengarang dari luar arsip.

2. Konsep sederhana (untuk non-teknis)

Analogi singkat: perpustakaan digital dengan pustakawan AI.



Yang perlu dipahami stakeholder:

- AI **tidak** membaca PDF mentah setiap kali; ia membaca teks OCR yang sudah disimpan.
- Kualitas jawaban bergantung pada kualitas OCR (scan buruk, PDF gambar tanpa teks).
- Ask AI bisa toleran sedikit pada variasi kata (semantic), tetapi tetap terikat konteks.
- Search lebih ketat pada kata kunci (full-text Whoosh), tanpa generasi jawaban panjang.


3. Search vs Ask AI

Aspek	Search (/search)	Ask AI (/ask)
Tujuan	Menemukan dokumen yang cocok dengan kata kunci	Menjawab pertanyaan natural language dari isi dokumen
Teknologi retrieval	Paperless Whoosh full-text (+ filter user, folder, tanggal)	Hybrid: Whoosh multi-query + ranking nama/isian + cosine embedding chunk
Generasi AI	Tidak (hanya snippet OCR ~320 karakter per dokumen)	Ya: OpenAI chat model (default gpt-4o-mini)
Output	Daftar dokumen, snippet, ringkasan folder/tanggal	Jawaban prose + daftar sumber (citations)
Riwayat	Tidak ada percakapan	Conversation + hingga 10 turn history
Pin / fokus	Filter folder	@ pin dokumen di Ask AI (focusDocIds, max 5)
Kapan dipakai	Cari file, cek ada/tidak, browsing cepat	Ringkas, jelaskan, bandingkan, daftar tematik


Search = mesin temu dokumen. **Ask AI** = asisten yang membaca cuplikan lalu menjawab. Keduanya memakai isolasi user yang sama, tetapi bukan duplikat fungsi.

4. Arsitektur RAG saat ini

DocSearch memakai **hybrid retrieval**: kombinasi pencarian kata kunci (Paperless) dan similarity vektor (embedding chunk), lalu **single-shot generation** dengan prompt terstruktur.



Saat user bertanya di Ask AI:





File inti implementasi: `app/src/lib/openai.ts` (retrieve + generate), `app/src/lib/embeddings.ts` (chunk + embed query), `sync-worker/src/embeddings.ts` (indexing saat OCR selesai / backfill), `app/src/app/api/chat/route.ts` (API Ask AI).

5. Komponen RAG: apa saja yang ada

Komponen	Implementasi sekarang	Catatan
Sumber dokumen	Teks OCR Paperless (content field)	Diambil setelah sync OCR_DONE; dedup hash antar user
Chunking	~1000 karakter, overlap 150	Sliding window; normalisasi spasi
Embedding model	text-embedding-3-small (default)	Env: OPENAI_EMBEDDING_MODEL
Penyimpanan vektor	JSON float[] di document_chunks.embedding	Per userId + paperlessDocumentId + chunkIndex
Indexing	sync-worker indexDocumentChunks + backfill batch	Clone chunk peer jika dokumen sama sudah di-embed user lain
Retrieval keyword	Paperless searchDocuments (Whoosh)	Multi-query expand, title + full-text, favorite folder boost
Retrieval semantic	Cosine similarity query vs chunk embeddings	Top chunks global, max ~12-20 chunk masuk konteks
Retrieval heuristik	bestContentWindow, nameOverlap, contentOverlap	Fallback jika embedding tidak ada
Generator	gpt-4o-mini (default)	temperature 0.2; max_tokens bervariasi per intent
Prompt / guardrails	SYSTEM_PROMPT + mode hint (list/detail/compare)	Jawab hanya dari konteks; format daftar/detail
Citations	filterCitationsUsedInAnswer	Sumber yang benar-benar dirujuk di jawaban

6. Alur teknis Ask AI (langkah demi langkah)





Detail retrieval dokumen (resolveDocs):

- Ekspansi query: beberapa varian frasa dari pertanyaan (expandSearchQueries).
- Parallel search: full-text + title-only untuk setiap varian.
- Boost folder favorit user jika path/file cocok kata kunci.
- Ranking: overlap nama file + overlap isi + boost favorit.
- Pin (@): hanya dokumen focusDocIds (max 5), skip broad search.
- Limit kandidat: default ~25 dokumen, list mode hingga 8 masuk konteks.

Detail buildContext:

- **Mode list:** tidak pakai embedding; cuplikan kaya per dokumen (~1400 char).
- **Mode detail/compare:** max 3 dokumen, chunk lebih dalam (~4500 char / 6 chunk/doc).
- **Mode default:** hybrid embedding: ambil top 12 chunk, max 3 chunk per dokumen.
- Fallback: bestContentWindow jika dokumen belum punya chunk embedding.
- Batas DB read: take 1200 chunk rows dari kandidat doc IDs.

7. Mode intent & batas konteks

Sistem mendeteksi intent dari kata kunci pertanyaan (bukan hardcode topik). Ini mengatur kedalaman bacaan vs cakupan dokumen.

Intent	Trigger contoh	Perilaku
list	cari, sebutkan, apa saja, dokumen tentang	Semua dokumen di konteks (max 8) dengan ringkasan per item
detail	jelaskan, analisis, poin penting, apa isi	Gali 1-3 dokumen paling relevan, chunk lebih banyak
compare	bandingkan, persamaan, perbedaan	Hanya dokumen pin/compare; struktur banding
default	pertanyaan umum	Hybrid retrieval standar

Konstanta batas (openai.ts):

Parameter	Nilai	Fungsi
MAX_CONTEXT_DOCS	8	Dokumen masuk prompt
MAX_CANDIDATE_DOCS	25	Kandidat dari Paperless
MAX_DOCS_DETAIL	3	Dokumen untuk mode detail
MAX_CHUNKS_IN_CONTEXT	12	Chunk embedding (default)
MAX_CHUNKS_DETAIL	20	Chunk embedding (detail)
CHUNK_SIZE / overlap	1000 / 150	Saat indexing
CONTENT_CHARS_PER_DOC	2800	Fallback teks per dokumen
CONTENT_CHARS_LIST	1400	Mode daftar
CONTENT_CHARS_DETAIL	4500	Mode detail
max_tokens jawaban	1400-2400	Tergantung intent
Chat history	10 turn	Percakapan lanjutan
Rate limit Ask AI	30/jam/user	API /api/chat

8. Scope, pin dokumen, dan isolasi user

Scope mode	Arti	Dokumen yang boleh di-AI
all	Default	Semua OCR_DONE/SKIPPED user

Scope mode	Arti	Dokumen yang boleh di-AI
folder	Folder tertentu	SyncFile di path prefix folder
docs	Daftar ID	Hanya docIds yang dipilih

- **Pin @:** focusDocIds (max 5) memaksa analisis hanya pada dokumen itu.
- **Embedding per user:** document_chunks.userId, meski Paperless doc sama bisa di-clone.
- **Search:** filter paperlessDocumentId ke set allowed user sebelum tampil.
- Tidak ada cross-user retrieval: allowedDocIds selalu dari sync_files user.

9. Batasan & risiko jawaban AI saat ini

Penting: AI bisa menjawab dengan nada yakin meski bukti kurang, terutama jika pertanyaan dan dokumen *topik mirip* tetapi *jenis berbeda* (contoh: ditanya kejadian bencana, dokumen hanya rencana preventif). Ini bukan bug satu kasus, melainkan risiko RAG generik.

- **Konteks terbatas:** tidak seluruh dokumen dibaca setiap turn; hanya top-N chunk.
- **Single-shot:** tidak ada langkah verifikasi bukti sebelum jawab final.
- **OCR error:** typo OCR, layout rusak, tabel hilang mengurangi akurasi.
- **Search vs semantic:** Search tidak fuzzy; Ask AI toleran semantic tapi tetap bisa salah jika retrieval salah.
- **PDF gambar:** bergantung OCR Paperless (OCR_MODE=auto); scan buruk = teks buruk.
- **Standalone PNG/JPG:** tidak di-ingest sebagai dokumen teks.
- **Tidak ada world knowledge guard:** model bisa mengisi celah jika prompt kurang ketat.
- **Biaya & latency:** detail mode + banyak chunk = token lebih besar.

10. Arah pengembangan (umum, bukan kasus per kasus)

Prinsip: aturan umum yang menutup banyak edge case tanpa daftar skenario panjang.

10.1 Tiga filter epistemik (wajib di prompt / pipeline)

- **Apa yang ditanya?** kejadian, rencana, perbandingan, daftar, angka, opini.
- **Apa bukti di OCR?** kutipan fakta yang mendukung klaim.
- **Jika bukti kurang:** jawab jujur, sebut ketidaksesuaian pertanyaan vs isi dokumen.

10.2 Rekomendasi implementasi bertahap

Prioritas	Usulan	Manfaat
P1	Perkuat SYSTEM_PROMPT: grounded + mismatch handling	Cepat, impact besar; kurangi jawaban 'nyambung tapi salah'
P2	Kerangka jawaban analisis standar (bukti / gap / interpretasi)	Struktur konsisten untuk semua topik
P3	Mode analisis: konteks lebih besar + pin dokumen	Kedalaman tanpa hardcode kasus
P4	Multi-step: retrieve → cek kecocokan bukti → jawab final	Model 'berpikir' tanpa rule per topik
P5	Model lebih kuat hanya untuk mode analisis	Kualitas reasoning, biaya terkendali

Tidak perlu: rule 'kalau bencana maka ...'. **Cukup:** bukti dulu, bedakan jenis klaim, akui jika tidak ada.

11. RAG ke depan: teknik yang cocok ditambahkan

Tabel berikut memetakan teknik RAG: yang sudah ada vs yang layak ditambahkan untuk DocSearch (arsip dokumen pemerintah, Bahasa Indonesia, skala 10k-100k dokumen).

Teknik RAG	Status sekarang	Cocok ditambahkan?	Catatan untuk DocSearch
Full-text keyword (BM25/Whoosh)	Ya (Paperless)	Pertahankan	Bagus untuk nama file, nomor surat, istilah resmi
Semantic chunk retrieval	Ya (cosine di Postgres)	Tingkatkan	Naikkan recall dengan reranker; index vector DB jika >100k chunk
Hybrid fusion (RRF)	Parsial (manual ranking)	Ya	Gabung skor Whoosh + embedding secara eksplisit
Query expansion	Ya (multi-query heuristik)	Ya	Bisa tambah LLM query rewrite ringan
Reranking (cross-encoder / Cohere)	Tidak	Ya (prioritas tinggi)	Top 50 chunk → rerank → top 12; akurasi retrieval naik signifikan
Metadata filtering	Parsial (folder, tanggal Search)	Ya	Filter jenis dokumen, tahun, path, status di Ask AI
Parent-child chunking	Tidak	Ya	Chunk kecil untuk search, parent section untuk konteks jawaban
Multi-step / agentic RAG	Tidak	Ya (mode analisis)	Retrieve → verify evidence → synthesize
Citation grounding / quote-only	Parsial	Ya	Wajib kutip span OCR sebelum klaim fakta
Self-RAG / reflection	Tidak	Opsional	Model cek 'apakah jawaban didukung konteks?' sebelum kirim
Graph RAG	Tidak	Opsional jangka panjang	Jika relasi antar dokumen (rujukan silang) jadi penting
Fine-tuning model	Tidak	Biasanya tidak perlu	RAG + prompt biasanya cukup untuk arsip institusi

12. Model AI sekarang vs rekomendasi ke depan

12.1 Model yang dipakai saat ini

Fungsi	Env var	Default	Kapan dipanggil
Chat / jawaban Ask AI	OPENAI_MODEL	gpt-4o-mini	Setiap pertanyaan Ask AI (stream)
Embedding chunk + query	OPENAI_EMBEDDING_MODEL	text-embedding-3-small	Indexing sync-worker; embedQuery saat Ask AI

12.2 Karakteristik model sekarang

- **gpt-4o-mini**: murah, cepat, cukup untuk ringkasan dan daftar; reasoning dalam untuk analisis kompleks.
- **text-embedding-3-small**: murah, dimensi efisien, cocok untuk semantic search Bahasa Indonesia campuran.
- Pricing estimasi di admin audit: default ~\$0.15/\$0.60 per 1M token chat, ~\$0.02 per 1M embed.

12.3 Rekomensi model ke depan (bertahap)

Use case	Model usulan	Alasan
Default Ask AI (tetap)	gpt-4o-mini	Biaya rendah, latency baik untuk 80% pertanyaan
Mode analisis / multi-doc reasoning	gpt-4o atau gpt-4.1-mini	Lebih patuh instruksi epistemik, reasoning lebih kuat
Query rewrite ringan	gpt-4o-mini	1 call murah sebelum retrieval
Embedding (tetap / upgrade)	text-embedding-3-small → large	Large jika recall semantic masih kurang setelah rerank
Reranker	Cohere rerank / bge-reranker lokal	Tidak generatif; fokus ranking chunk
OCR (bukan OpenAI)	Paperless Tesseract	OCR tetap di Paperless; OpenAI tidak menggantikan OCR

Strategi biaya: model kuat hanya untuk mode analisis atau user role tertentu; embedding di-backfill batch (EMBED_BACKFILL_BATCH); audit OpenAI di Admin.

13. Biaya, audit, dan operasional

- Setiap Ask AI mencatat promptTokens, completionTokens, embeddingTokens ke audit.
- Admin → Audit: agregasi biaya estimasi USD (openai-pricing.ts).
- Rate limit: 30 pertanyaan/jam/user pada /api/chat.
- Embedding backfill: sync-worker batch default 5 dokumen per siklus.
- Tanpa OPENAI_API_KEY: Ask AI error; Search tetap jalan (tanpa generasi).
- Health check: /api/health melaporkan openai: true/false.

Env terkait AI (.env.example):

```
OPENAI_API_KEY, OPENAI_MODEL, OPENAI_EMBEDDING_MODEL, OPENAI_PRICE_CHAT_INPUT_PER_MTok,  
OPENAI_PRICE_CHAT_OUTPUT_PER_MTok, OPENAI_PRICE_EMBED_PER_MTok, EMBED_BACKFILL_BATCH
```

14. Kemungkinan pertanyaan (materi demo & pelatihan)

Bab ini mengumpulkan pola pertanyaan yang **kemungkinan besar** muncul saat penggunaan nyata, demo ke stakeholder, atau uji coba pelatihan. Gunakan sebagai skenario latihan: cek apakah jawaban terikat dokumen, sumber tercantum, dan AI mengakui jika bukti tidak ada.

Tips demo: mulai dari Search (temukan file), lalu Ask AI (ringkas isi). Untuk analisis mendalam, pin 1-2 dokumen dengan @ sebelum bertanya detail.

14.1 Pola intent yang sistem mendeteksi

Intent	Kata kunci umum	Contoh singkat	Harapan jawaban
list	cari, sebutkan, apa saja, dokumen tentang	Ada dokumen tentang RPJMN?	Daftar semua dokumen relevan di konteks + ringkasan per item
detail	jelaskan, uraikan, poin penting, apa isi	Jelaskan isi undangan rapat itu	Jawaban langsung + poin fakta dari OCR
compare	bandingkan, persamaan, perbedaan	Bandingkan dua draft laporan ini	Hanya dokumen pin; persamaan, beda, kesimpulan
default	pertanyaan umum	Apa topik utama dokumen terkait anggaran?	Hybrid retrieval standar

14.2 Ask AI: pencarian & daftar dokumen

- Ada dokumen apa saja tentang perencanaan pembangunan?
- Cari file terkait reformasi birokrasi di arsip saya.
- Sebutkan 5 dokumen terbaru tentang infrastruktur.
- Apa saja undangan rapat yang membahas evaluasi program?
- Lihat dokumen yang relevan dengan kebijakan fiskal.
- Berapa dokumen tentang mitigasi bencana yang sudah di-scan?
- Temukan laporan progress yang terkait Sumatera.
- Daftar berkas PDF tentang kerja sama internasional.

Modul terbaik: Ask AI (mode list) atau Search jika user hanya ingin daftar file cepat.

14.3 Ask AI: ringkas & detail isi

- Ringkas isi dokumen ini dalam 5 poin utama.
- Jelaskan agenda rapat yang tercantum di undangan.
- Apa keputusan atau kesimpulan dalam nota dinas ini?
- Sebutkan tanggal, nomor surat, dan pihak yang terlibat.
- Uraikan rekomendasi teknis yang disampaikan di laporan.
- Apa isi pokok bahasan dalam memo internal?
- Poin penting dari draft kebijakan ini apa saja?
- Siapa peserta atau undangan yang disebutkan di dokumen?
- Ada target atau indikator kinerja yang disebut? Sebutkan.

Tips: pin dokumen (@) lalu tanya detail agar konteks tidak tersebar ke file lain.

14.4 Ask AI: perbandingan & multi-dokumen

- Bandingkan versi draft A dan draft B: apa yang berubah?
- Apa persamaan dan perbedaan dua laporan evaluasi ini?
- Dokumen mana lebih lengkap membahas aspek anggaran?
- Bedakan fokus laporan tahun ini vs laporan tahun lalu.
- Apakah rekomendasi di nota 1 sama dengan nota 2?

Syarat: pin 2-5 dokumen (@) sebelum bertanya; mode compare aktif otomatis.

14.5 Pertanyaan lanjutan (multi-turn)

Ask AI menyimpan hingga 10 turn riwayat. Contoh alur percakapan yang realistis:

Turn	Pertanyaan user	Tujuan uji
1	Ada dokumen tentang rapat koordinasi program?	Retrieval awal, mode list
2	Yang terbaru saja	Recency + filter implisit
3	Jelaskan isi nomor 2	Detail pada item daftar sebelumnya
4	Siapa yang diundang?	Follow-up fakta spesifik
5	Ada tanggal pelaksanaan?	Cek bukti OCR vs mengarang
6	Kalau tidak ada, katakan tidak ditemukan	Uji kejujuran AI

- Dari poin 3, elaborasi lebih dalam tentang risiko yang disebut.
- Buat ringkasan eksekutif 3 paragraf untuk atasan.
- Ubah ke format bullet untuk presentasi.
- Apa yang belum dijelaskan di dokumen ini?

14.6 Search: pertanyaan kata kunci (bukan generatif)

- RPJMN 2025
- undangan rapat direktur
- nota dinas anggaran
- evaluasi program 2024
- draft laporan akhir
- surat edaran internal
- rencana aksi mitigasi
- TOR konsultan

Perbedaan: Search cocok untuk exact/partial keyword dan browsing cepat; tidak menghasilkan jawaban naratif panjang.

14.7 Pertanyaan stakeholder (non-teknis)

Apakah AI menggantikan pegawai yang membaca dokumen?

Tidak. AI mempercepat penemuan dan ringkasan; pegawai tetap memvalidasi sumber dan keputusan.

Apakah jawaban AI selalu benar?

Tidak. Jawaban terikat cuplikan OCR yang diambil; bisa kurang lengkap atau salah jika retrieval/topik mirip.

Bisa dipakai untuk dokumen sensitif?

Isolasi per user; data cuplikan dikirim ke OpenAI jika Ask AI aktif. Kebijakan institusi tentang cloud AI harus dipatuhi.

Berapa biaya per pertanyaan?

Tergantung panjang konteks; estimasi di Admin Audit. Default model murah (gpt-4o-mini).

Apakah semua PDF di cloud langsung bisa ditanya?

Hanya PDF yang sudah di-ingest dan OCR selesai (status OCR_DONE/SKIPPED).

Beda dengan ChatGPT umum?

DocSearch jawab dari arsip Anda yang sudah di-OCR, dengan scope user dan citations dokumen.

14.8 Pertanyaan teknis & operasional

- Kenapa Ask AI bilang tidak ada dokumen? (belum ingest / scope folder / query terlalu umum)
- Kenapa Search ada hasil tapi Ask AI jawab generik? (retrieval berbeda; cek citations)
- Kenapa embedding belum jalan? (OPENAI_API_KEY, backfill worker, dokumen baru)
- Berapa lama OCR sebelum bisa ditanya? (tergantung antrian Paperless)
- Bisa batasi AI hanya ke satu folder? (scope folder di conversation)
- Apakah ada rate limit? (30 pertanyaan/jam/user)
- Log aktivitas AI ada di mana? (Admin Audit)

14.9 Pertanyaan berisiko atau sering menantang

Latihan penting: pertanyaan di bawah sering menguji apakah AI menjawab dari bukti atau mengarang. Idealnya AI membedakan jenis klaim dan mengakui gap.

Pertanyaan contoh	Risiko	Respons ideal
Apa bencana yang terjadi tahun ini?	Dokumen hanya rencana preventif, bukan laporan kejadian	Jelaskan dokumen membahas mitigasi/rencana, bukan daftar kejadian
Berapa total anggaran program X?	Angka tersebar / tidak ada di OCR	Sebut angka hanya jika ada kutipan; otherwise tidak ditemukan
Siapa yang bersalah / siapa paling bertanggung jawab?	Pertanyaan normatif di luar teks	Hanya fakta yang tertulis; tidak menilai
Prediksi dampak ke depan?	Generatif tanpa bukti	Batasi pada proyeksi yang eksplisit di dokumen
Ringkas semua dokumen di cloud	Scope terlalu luas, konteks terbatas	Minta spesifik topik/folder atau pin dokumen
Apa isi dokumen yang belum di-scan?	Tidak ada teks OCR	Jelaskan perlu ingest/OCR dulu
Terjemahkan ke Inggris seluruh isi	Token besar, hilang struktur	Pin satu dokumen; ringkas per bagian

14.10 Matriks cepat: pertanyaan → modul → tips

Kebutuhan user	Modul	Contoh pertanyaan	Tips sukses
Cari file cepat	Search	nota dinas reformasi	Gunakan kata kunci unik; filter folder/tanggal

Kebutuhan user	Modul	Contoh pertanyaan	Tips sukses
Daftar tematik	Ask AI	Apa saja dokumen tentang ...?	Scope folder jika topik besar
Ringkasan eksekutif	Ask AI + pin	@laporan.pdf ringkas 5 poin	Pin 1 dokumen; mode detail
Banding versi	Ask AI + pin 2	Bandingkan @draft1 @draft2	Max 5 pin; pertanyaan eksplisit compare
Eksplorasi bebas	Ask AI	Apa yang terkait dengan ...?	Cek citations; lanjutkan dengan pertanyaan spesifik
Audit penggunaan	Admin	(bukan pertanyaan AI)	Panel Audit: token & estimasi biaya

14.11 Checklist sesi demo (15 menit)

- 1. Login user demo dengan kredensial cloud valid.
- 2. Library: tunjukkan folder sudah OCR (ikon status).
- 3. Search: kata kunci spesifik, tunjuk snippet OCR.
- 4. Ask AI list: 'Sebutkan dokumen tentang [topik yang ada di arsip demo]'.
- 5. Pin 1 dokumen (@): 'Jelaskan poin penting'.
- 6. Follow-up: 'Siapa pihak yang disebut?' (uji multi-turn).
- 7. Pertanyaan sulit: topik mirip tapi jenis berbeda (uji kejujuran).
- 8. Tunjuk citations / sumber di jawaban.
- 9. Admin (jika audiens teknis): cuplikan audit OpenAI.
- 10. Tutup: batasan OCR, isolasi user, tidak menggantikan validasi manusia.

15. FAQ AI

Apakah AI membaca semua dokumen saya setiap kali?

Tidak. Sistem memilih kandidat via Paperless search + ranking, lalu memasukkan sebagian cuplikan (chunk/teks) ke prompt. Batas eksplisit: ~8 dokumen, ~12-20 chunk.

Kenapa jawaban bisa 'nyambung' tapi tidak tepat?

Retrieval menemukan dokumen topik mirip, model mengisi celah tanpa bukti kuat. Solusi: prompt epistemik + multi-step verify + pin dokumen untuk analisis mendalam.

Search tidak menemukan, tapi Ask AI menjawab?

Ask AI bisa semantic; Search strict keyword. Bisa juga Ask AI mengambil dokumen kurang relevan lalu menjawab generik. Selalu cek citations.

Apakah typo di dokumen ditangani?

Tidak ada spell-check. OCR typo mengurangi match Search; Ask AI sedikit toleran via semantic.

Bisa tanya dokumen gambar / scan buruk?

Hanya jika OCR Paperless menghasilkan teks. Kualitas scan menentukan hasil.

Data dikirim ke OpenAI?

Ya: cuplikan teks OCR (chunk) dan pertanyaan user dikirim ke API OpenAI saat Ask AI / embedding.

Skala 10.000-100.000 dokumen?

Arsitektur single-node masih masuk akal dengan batch embedding + Whoosh Paperless. Di skala besar, pertimbangkan vector DB + reranker + worker embedding terpisah.

Langkah pertama pengembangan AI?

Perkuat grounded prompt + kerangka jawaban (bukti/gap), lalu mode analisis dengan konteks lebih besar.

Penutup. AI di DocSearch adalah lapisan RAG di atas OCR yang sudah ada. Kekuatan utama: jawaban terikat arsip dan isolasi user. Prioritas pengembangan: retrieval lebih akurat, jawaban lebih jujur saat bukti kurang, dan mode analisis yang dalam tanpa hardcode setiap skenario bisnis.